

[] Task 1: ■■■■■■■■■■

- [] Task 2: ■■■■■■■■

- **Priority:** high
- **Depends On:** Task 1
- **Description:**
 - ■■■■■■■■■■ Article ■■■■■■■■■■ ArticleContent ■■■■■■■■■■ CrawlProgress ■■■■■■■■■■
 - ■■■ JSON ■■■■■■■■■■ JSON ■■■■■■■■■■ JSON
 - ■■■ CSV ■■■■■■■■■■■■■■■■■■ CSV ■■■
 - ■■■■■■■■■■■■ ID ■■■■■■■■■■■■■■■■■■ URL ■■■■■■■■■■
 - ■■■■■■■■■■■■ last_crawled_at ■■■■■■■■■■ ID ■■■
- **Acceptance Criteria Addressed:** AC-4, AC-5
- **Test Requirements:**
 - programmatic TR-2.1: JSON ■■■■■■■■■■■■■■■■■■ json.load ■■■■■
 - programmatic TR-2.2: CSV ■■■■ pandas ■■■■■■■■■■■■■■■■■■■■■■■■■■■■■■

- `programmatic` TR-2.3: `article_id`
- `programmatic` TR-2.4:
- **Notes:** `dataclass` `pydantic`

[] Task 3: HTTP

- **Priority:** high
- **Depends On:** Task 1
- **Description:**
 - `requests` `headers` `cookies`
 - `/` `/` `/` `/`
 - `gentle` `standard` `fast`
 - `User-Agent`
 - `robots.txt`
- **Acceptance Criteria Addressed:** AC-6, AC-10
- **Test Requirements:**
 - `programmatic` TR-3.1: `10` `min/max`
 - `programmatic` TR-3.2: `gentle/standard/fast`
 - `programmatic` TR-3.3: `User-Agent`
 - `human-judgement` TR-3.4: `robots.txt`
- **Notes:** `time.sleep` + `random.uniform`

[] Task 4:

- **Priority:** high
- **Depends On:** Task 3
- **Description:**
 - `exponential backoff`
 - `HTTP 429/500/502/503/504`
 - `HTTP 400/401/403/404`
 -
 -
- **Acceptance Criteria Addressed:** AC-7

- **Test Requirements:**
- `programmatic` TR-4.1: `max_retries`
- `programmatic` TR-4.2: `1s, 2s, 4s, ...` `max_backoff`
- `programmatic` TR-4.3: `404`
- `programmatic` TR-4.4:
- **Notes:** `tenacity`

[] Task 5: ■■■■■■

- [illegible]

[] Task 6: ■■■■■■■■

- [illegible]

-  URL 
- 
- **Acceptance Criteria Addressed:** AC-3
- **Test Requirements:**
- **programmatic** TR-6.1: 
- **programmatic** TR-6.2:  URL 
- **programmatic** TR-6.3:  $\geq 95\%$  $< 1\%$
- **human-judgement** TR-6.4: 
- **Notes:**  API  stream 

[] Task 7: ■■■■■■■■■■

- [illegible]

[] Task 8: ■■■■■■■■

- **Priority:** medium
- **Depends On:** Task 1
- **Description:**

- INFO/WARNING/ERROR
-
- / / / /
-
- failed_articles.json
- **Acceptance Criteria Addressed:** AC-9
- **Test Requirements:**
- programmatic TR-8.1:
- programmatic TR-8.2:
- programmatic TR-8.3:
- human-judgement TR-8.4:
- **Notes:** Python logging tqdm

[] Task 9:

- **Priority:** high
- **Depends On:** Task 2, Task 5, Task 6, Task 7, Task 8
- **Description:**
- CLI main.py crawl/list/export/resume
- → → → → →
- Ctrl+C
- README
- **Acceptance Criteria Addressed:** AC-1, AC-3, AC-5, AC-9
- **Test Requirements:**
- programmatic TR-9.1: python main.py crawl --config config.yaml
- programmatic TR-9.2: Ctrl+C
- programmatic TR-9.3: resume
- human-judgement TR-9.4: README
- **Notes:** click argparse CLI

[] Task 10:

- **Priority:** medium

- **Depends On:** Task 9
- **Description:**
 - 
 - 
 -  docstring
 - 
 - 
- **Acceptance Criteria Addressed:** AC-7, AC-10
- **Test Requirements:**
 - programmatic TR-10.1:  $\geq 70\%$
 - programmatic TR-10.2: 
 - human-judgement TR-10.3: 
 - human-judgement TR-10.4: 
- **Notes:**  pytest  README  LICENSE 